实验一：文本分类

在这次的任务中，我们要做的是使用给定的训练集训练出一个模型，我们使用这个模型对于一个unlabeled data来进行分类。模型的输入是unlabeled data，输出是一个数字，最后通过和标签计算交叉熵得到loss并进行模型的更新。

一、数据集处理

当看了数据集里面的数据后，很显然我们会有两个问题：
第一个问题就是:我们现在只有训练集，没有验证集，我们该如何训练这个模型呢？ 这个问题很简单，我们可以将训练集看作一个数据的全集，在train_data.csv里面重新划分训练集，验证集和测试集，然后训练出这个模型。困难的地方在于，划分的比例是多少？由于很难找到一个绝对好的划分方法，所以我选择了最普遍的方法，也就是80：10：10。但由于并不确定这个划分方法是好还是坏，所以我又取了85：5：10以及90：5：5这两种划分方法来进行比较，这样子，至少能在三者中取到一个相对好的。
通过统计可以得到：原始数据共有7368条标注文本、2457条无标签文本，10个类别各有705-747条；原文长度中位数为1139字符，无缺失和完全重复文本。为了尽量保持类别比例，我们采用分层划分，并固定随机种子42，得到的划分数据如下：

划分	训练:验证:测试	训练数	验证数	测试数
A	80:10:10	5894	737	737
B	85:5:10	6262	369	737
C	90:5:5	6630	369	369

第二个问题是数据本身的问题。 因为我们知道，在进行训练之前，需要将文本转换成向量，通过训练得到最后的模型。但是只要看了一下数据本身就会发现：我们要分类的文本是信件。在我们的常识中，信件的主题，也就是subject，大概率会和信件的类型相关，所以与其把信件一股脑的变成向量直接塞进模型里面进行训练，我们不如通过判断先提取一点更加有效的信息，通过保留相对重要的信息，来提升模型的准确度。相同的想法也可以被运用在author上面。按照这个想法，我们可以罗列出四种情况：raw,body_only,body_subject,body_subject_author,然后通过这四种对比判断，最后训练得到一个更加有效，也更加精准的模型。

二、模型选择

现在，我们的准备工作就做的差不多了，于是我们来选择模型。
我选择的模型分别是Linear SVM和MLP。Linear SVM在高维空间中寻找最大间隔的线性分类边界，适合作为稀疏文本特征的基线；MLP通过隐藏层和ReLU学习非线性关系，可以用来观察更复杂的模型是否带来提升。两者输入的是同一套TF-IDF向量，因此这里比较的是线性与非线性模型，而不是高维与低维。

模型	候选参数与训练设置
Linear SVM	C∈{0.1, 1, 10}；max_iter=5000
MLP	h∈{(50,), (100,), (100,50)}；α∈{0.0001, 0.001}

MLP使用Adam、初始学习率0.001，训练300轮，不早停。三种划分、四种文本和九种模型配置共108组。我们先比较验证Accuracy，并列时比较宏F1；测试分数不参与排序。下表是两个模型分别选出的配置，均为85:5:10、标题+正文+作者，F1为宏平均。

先看数据划分。固定SVM C=1和标题+正文+作者，80:10:10、85:5:10、90:5:5的验证Accuracy分别为94.98%、96.48%、94.85%。这样看，85:5:10在这次比较中更好，但训练样本增加并没有带来单调提升。原因是划分改变时，验证样本也变了；A/B的本地测试集相同，C不同，不能仅凭这些数字断言某个比例普遍最好。

再看文本处理。固定85:5:10和SVM C=1，body_only、subject_body、raw、subject_body_author的验证Accuracy分别为94.31%、96.21%、96.21%、96.48%。保留标题后结果有所提升，符合我们开始时的猜测；加入作者后，验证集又多预测正确了1条。不过，369条验证样本中1条就约占0.27个百分点，这个提升很小，也可能与作者和类别的关联有关，还需要按作者分组或更换随机种子验证。

最后看模型本身。图中的MLP loss总体下降，但更低的训练loss不能直接说明分类效果更好。固定85:5:10、标题+正文+作者和α=0.001，隐藏层为(50,)、(100)、(100,50)时，验证Accuracy为96.21%、95.93%、94.04%。增加神经元和层数并没有得到更好的结果。复杂模型可能更依赖优化与正则化，也有过拟合风险；现有日志没有逐轮验证loss，因此不能仅凭训练曲线确定过拟合发生的轮次。SVM在这次实验中略优于MLP，也说明高维文本特征下，线性模型已经能有效区分类别。

5. 最后，我们选择什么方案？

需要说明的是，原有训练脚本为每个候选都记录了测试指标，这次报告属于对已有实验的回顾分析，不能说测试集从未被查看。我们的排序只依据验证结果；后续更严格的做法是先锁定方案，再评价独立测试集。Notebook保留读取、校验、画图与预测代码，依赖版本和输入摘要保存在evidence_manifest.json中。本次重新拟合核验了最终SVM；MLP结果及loss曲线来自既有日志，未重新训练。